

JudgeMesh 分布式在线判题系统测试分析报告

案卷号：JudgeMesh-TEST-2026-01

日期：2026-06-05

项目名称：JudgeMesh 分布式在线判题系统

文档类型：测试分析报告

作者：贾呈煜

完成日期：2026-06-05

签收人：待定

签收日期：待定

修改情况记录

版本号	修改批准人	修改人	修改日期	修改内容	签收人
V1.0	待定	贾呈煜	2026-06-05	根据《测试分 析报告编写规 范》、项目设 计文档与汇报 PPT 测试结果 形成正式版	待定

1 引言

1.1 编写目的

本文档用于汇总 JudgeMesh 分布式在线判题系统的测试工作、测试结果和质量结论，说明系统在功能闭环、性能指标、分布式判题、故障恢复和高并发读写场景中的实际表现。本文档面向任课教师、答辩评审、项目组成员和后续维护人员，作为课程项目验收、答辩汇报和系统交付的测试依据。

1.2 背景

被测试软件系统为 JudgeMesh 分布式在线判题系统。系统面向算法课程、程序设计竞赛训练和课程答辩演示场景，由浏览器前端、Spring Cloud Gateway、user-service、problem-service、submit-service、judge-dispatcher、judge-worker 池、RabbitMQ、Redis、MySQL、MinIO、etcd、Prometheus、Grafana 等组件组成。

测试环境采用答辩版 4 节点高可用拓扑，部署为 2 个 App 节点与 2 个 Judge 节点，judge-dispatcher 固定 3 副本，judge-worker 配置为 3 至 8 个弹性副本，单实例 JUDGE_MAX_CONCURRENCY=1。该环境用于验证课程目标负载下的功能正确性和分布式特性，和完整生产环境相比，MySQL、Redis、RabbitMQ 等中间件未全部按生产级多副本高可用部署。

1.3 定义

术语	定义
OJ	Online Judge，在线判题系统
AC	Accepted，答案正确
WA	Wrong Answer，答案错误
TLE	Time Limit Exceeded，超出时间限制
MLE	Memory Limit Exceeded，超出内存限制
RE	Runtime Error，运行时错误
CE	Compile Error，编译错误
SE	System Error，系统错误
P99	第 99 百分位响应时间，用于衡量长尾延迟
Worker	判题执行节点，负责拉取用例、编译运行和输出比对
Dispatcher	判题调度器，负责消费队列、选择 Worker 和故障重派

1.4 参考资料

资料名称	来源
《测试分析报告编写规范》	docs/template/测试分析报告编写规范.doc
JudgeMesh 测试策略	docs/design/10-测试策略.md
JudgeMesh 测试数据文档	docs/dev/05-测试数据文档.md
JudgeMesh 判题流水线	docs/design/05-判题流水线.md
JudgeMesh 服务治理与容错	docs/design/06-服务治理.md

资料名称	来源
JudgeMesh 可观测性方案	docs/design/07-可观测性.md
JudgeMesh 分布式在线判题系统汇报	docs/JudgeMesh 分布式在线判题系统汇报.pdf

2 测试概要

测试标识	测试内容	工具或脚本	目标	实际执行情况
T-01	冒烟测试	smoke-test.sh	验证登录、A+B 提交、分布式任 务派发和单节点 恢复流程	已执行， Python/C++ A+B 样例与核心链路 可演示
T-02	提交接口纯 QPS 压测	wrk -t4 -c50 -d300s -s scripts/loadtest-submit.sh	验证提交记录落 库与 RabbitMQ 入队的同步阶段 P99 < 200ms	已执行 5 分钟， 50 并发
T-03	分布式端到端判 题压测	node scripts/demo-distributed-queue-1-workers	验证登录、提交、 MQ 派发、Worker 判题、结果回写 完整闭环 P99 < 8s	已执行，总 60 用 户、并发 30
T-04	单 Worker 故障恢 复	demo-distributed-queue-1-workers + 手工停止 worker-2	验证故障节点黑 名单、任务重分 发与剩余 Worker 接管	已执行，总 30 请 求、并发 15、30 虚拟用户
T-05	排行榜查询压测	JMeter	验证 GET /api/rank/global P99 < 50ms	已执行，可视化 报告数据进入汇 报 PPT
T-06	题目详情查询压 测	JMeter	验证 GET /api/problem/{id} P99 < 100ms， Redis 命中率 > 90%	已执行，可视化 报告数据进入汇 报 PPT

测试标识	测试内容	工具或脚本	目标	实际执行情况
T-07	测试数据覆盖检查	docs/dev/05-测试数据文档.md	覆盖用户权限、题目、提交状态、比赛、分布式判题、高并发压测数据	已按统一测试数据口径组织

测试工作与原测试策略保持一致，重点覆盖提交接口纯 QPS、端到端判题、排行榜查询、题目详情读取和故障恢复五类核心场景。Special Judge、交互题、长时间生产级容量压测、etcd 整体故障和网络分区恢复演练未纳入本次最终验收范围。

3 测试结果及发现

3.1 T-01 冒烟测试

冒烟测试覆盖 Python/C++ A+B 样例提交、分布式任务派发和单节点故障自动恢复流程。测试表明，用户提交后系统能够完成提交入库、消息投递、dispatcher 派发、worker 判题、结果回写和前端可见状态更新，核心业务链路无断点。

3.2 T-02 提交接口纯 QPS 压测

测试对象为 POST /api/submit 的同步阶段，即提交记录落库和任务入队 RabbitMQ。执行配置为 4 线程、50 并发、持续 300 秒。

指标	实测结果	目标	结论
平均响应时间	42.37 ms	-	正常
P90 / P99	78 ms / 156 ms	P99 < 200 ms	达标
吞吐量	124.68 req/s	常态 > 100 QPS	达标
错误率	0%	0%	达标

发现：提交入口已与慢判题流程解耦，峰值流量采用“先落库再异步入队”的方式处理，长尾响应满足课程设计指标。

3.3 T-03 分布式端到端判题压测

测试覆盖用户登录、题目提交、MQ 消息派发、Worker 节点判题、结果回写数据库及前端状态轮询的完整流程。执行配置为总 60 用户、并发 30。

指标	实测结果	目标	结论
平均响应时间	1864 ms	-	正常
P90	2987 ms	-	正常
P95	3721 ms	-	正常
P99	6418 ms	< 8 s	达标
最大响应耗时	7346 ms	< 8 s 目标附近	可接受
判题结果分布	statusCounts={"AC":60}	无异常结果	达标
Worker 负载分布	workerCounts={"worker-1":20,"worker-2":20,"worker-3":20}	各 Worker 均衡分机	达标

发现：调度算法在 3 个 Worker 间实现了均衡分发，未出现判题错误、超时丢失或单节点过载。

3.4 T-04 故障恢复与高可用验证

测试通过手工停止 worker-2 模拟单 Worker 节点故障，验证调度器节点黑名单机制和剩余 Worker 自动接管能力。执行配置为总 30 请求、并发 15、30 虚拟用户。

指标	实测结果	目标	结论
平均响应时间	2149 ms	-	正常
P90	3364 ms	-	正常
P95	4012 ms	-	正常
P99	6895 ms	< 8 s	达标
任务状态分布	AC: 30	全量成功	达标
存活节点负载	worker-1 / worker-3 均分 15 / 15	故障后自动重分发	达标

发现：单 Worker 宕机未引发流程中断，系统能够跳过故障节点并由存活节点继续处理任务，具备基础高可用能力。

3.5 T-05 排行榜查询压测

测试对象为 GET /api/rank/global，使用 JMeter 生成可视化性能报告。

指标	实测结果	目标	结论
平均响应时间	11.82 ms	-	正常
P99 延迟	43 ms	< 50 ms	达标
吞吐量	1386.24 req/s	高并发读稳定	达标
错误率	0%	0%	达标

发现：排行榜读请求主要由 Redis ZSet 支撑，未观察到明显数据库穿透压力。

3.6 T-06 题目详情查询压测

测试对象为 GET /api/problem/{id}，使用 JMeter 生成可视化性能报告。

指标	实测结果	目标	结论
平均响应时间	26.41 ms	-	正常
P99 延迟	87 ms	< 100 ms	达标
吞吐量	1642.57 req/s	高并发读稳定	达标
错误率	0%	0%	达标
Redis 命中率	95%+	> 90%	达标

发现：题目详情读多写少场景通过缓存层显著降低 MySQL 压力，符合概要设计中的 Cache-Aside 与多级缓存预期。

4 对软件功能的结论

4.1 用户与权限功能

4.1.1 能力 系统支持管理员、出题人、学生、游客等角色，并通过 JWT 与 RBAC 控制访问。测试数据覆盖核心账号、禁用账号、零余额账号和低权限账号，能够支撑登录、权限校验和页面权限验证。

4.1.2 限制 本次报告未展开列出全部权限矩阵的逐项截图结果，结论主要基于冒烟测试、接口联调和测试数据覆盖情况。

4.2 题目与测试用例管理功能

4.2.1 能力 系统支持题目元数据管理、测试用例上传、manifest 管理和 Worker 下载测试数据。测试数据覆盖基础题、分支题、性能边界题、TLE 场景、MLE 场景和资源缺失 SE 场景。

4.2.2 限制 本期明确不覆盖 Special Judge 和交互题，相关测试项按需求范围跳过。

4.3 代码提交与判题功能

4.3.1 能力 系统已验证提交入库、MQ 入队、dispatcher 派发、worker 判题、结果回写和状态查询闭环。端到端判题压测中 60 次提交全部 AC，P99 为 6418 ms，满足 $< 8\text{ s}$ 的目标。

4.3.2 限制 本次高并发端到端压测以稳定回显题和标准 A+B 样例为主，未进行长时间混合难度题目的容量边界压测。

4.4 排行榜与比赛功能

4.4.1 能力 排行榜查询 P99 为 43 ms，吞吐量 1386.24 req/s，错误率 0%，说明 Redis ZSet 排名方案能够满足课程目标负载下的高并发读需求。比赛数据覆盖报名、排行榜和封榜前后场景。

4.4.2 限制 封榜、解榜和 WebSocket 长连接稳定性在本次报告中以功能联调和设计验证为主，未单独开展长时间连接保持测试。

4.5 可观测性与高可用功能

4.5.1 能力 系统集成 Prometheus、Grafana、SkyWalking 和日志观测方案。单 Worker 故障恢复测试中 30 个请求全部 AC，剩余节点均分任务，P99 为 6895 ms，验证了 worker 黑名单和重分发机制。

4.5.2 限制 本次故障测试覆盖单 Worker 宕机，尚未覆盖 etcd 集群整体故障、RabbitMQ 长时间不可用、跨节点网络分区等更强故障模型。

5 分析摘要

5.1 能力

经测试证实，JudgeMesh 已达到本次课程项目设定的核心目标：提交接口同步阶段 P99 为 156 ms，低于 200 ms；端到端判题 P99 为 6418 ms，低于 8 s；排行榜查询 P99 为 43 ms，低于 50 ms；题目详情 P99 为 87 ms，低于 100 ms；关键压测场景错误率均为 0%。RabbitMQ 实现了提交削峰填谷，etcd 选主与 worker 黑名单机制支撑调度高可用，Redis 排行榜与缓存层支撑高并发读请求。

5.2 缺陷和限制

本次测试发现的主要限制不是已暴露的功能性缺陷，而是测试覆盖边界：生产级长时间容量压测不足；etcd 整体故障和网络分区恢复尚未演练；KEDA 基于队列长度的自动扩缩容尚可继续完善；WebSocket 长连接稳定性可以补充更长时间测试；MySQL、Redis、RabbitMQ 在答辩环境中未全部按生产级高可用形态部署。

5.3 建议

后续建议补充 30 分钟至 2 小时的持续容量压测，增加混合题型和混合语言提交；补充 etcd 节点故障、网络分区和 RabbitMQ 恢复演练；引入 KEDA 根据 RabbitMQ 队列长度自动扩缩容；为 WebSocket 排行榜推送增加长连接稳定性测试；保留 JMeter、wrk、Grafana 截图和 Prometheus 查询结果作为归档证据。

5.4 评价

综合功能测试、性能压测和故障恢复演练结果，JudgeMesh 已达到需求规约和概要设计中定义的课程项目验收目标，可以作为分布式在线判题系统课程项目交付和答辩展示版本使用。

6 测试资源消耗

资源类别	使用情况
测试人员	项目组成员共同完成，测试报告编写者为贾呈煜
测试环境	4 节点答辩版拓扑，2 App 节点 + 2 Judge 节点
应用副本	judge-dispatcher 3 副本，judge-worker 3 至 8 弹性副本

资源类别	使用情况
主要工具	wrk、JMeter、demo-distributed-load.mjs、smoke-test.sh、Prometheus、Grafana
主要数据	8 个核心用户账号、30/60/120 压测账号段、10 道题目测试数据、AC/WA/RE/TLE/MLE/SE 状态样例
机时消耗	单项压测以 1 至 5 分钟为主，另包含冒烟测试、故障注入和报告整理时间